

**T.C.
FIRAT ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ**

**UYDU VE İHA VERİLERİYLE DESTEKLENEN
KATMANLI ORMAN YANGINI ALGILAMA SİSTEMİ**

Ahmet MEŞİŞ
Ali EROL

Tez Danışmanı
Doç. Dr. Ahmet ÇINAR

BİTİRME TEZİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

ELAZIĞ - 2026

T.C.
FIRAT ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ

UYDU VE İHA VERİLERİYLE DESTEKLENEN
KATMANLI ORMAN YANGINI ALGILAMA SİSTEMİ

Ahmet MEŞİŞ

Ali EROL

BİTİRME TEZİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Bu bitirme tezi/...../2026 tarihinde, aşağıda belirtilen jüri tarafından oybirliği/oyçokluğu ile başarılı/başarısız olarak değerlendirilmiştir.

(İmza)

Doç. Dr. Ahmet ÇINAR

(İmza)

Üye

(İmza)

Üye

ÖZGÜNLÜK BİLDİRİMİ

Bu çalışmada, başka kaynaklardan yapılan tüm alıntılar, ilgili kaynaklar referans gösterilerek açıkça belirtildiğini, alıntılar dışındaki bölümlerin, özellikle projenin ana konusunu oluşturan teorik çalışmaların ve yazılım/donanımın benim tarafımdan yapıldığını bildiririm.

Fırat Üniversitesi

03.02.2026

Bilgisayar Mühendisliği Bölümü

23119 Elazığ

Öğrencilerin Adı Soyadı

Ahmet MEŞİŞ

Ali EROL

BENZERLİK BİLDİRİMİ

AliErol_AhmetMeşiş_BitirmeTezi_202526Guz.pdf

ORJİNALLIK RAPORU

%**5**

BENZERLİK ENDEKSİ

%**3**

İNTERNET KAYNAKLARI

%**1**

YAYINLAR

%**3**

ÖĞRENCİ ÖDEVLERİ

BİRİNCİL KAYNAKLAR

1

Submitted to Firat Üniversitesi

Öğrenci Ödevi

%**2**

2

content.iospress.com

İnternet Kaynağı

%**1**

3

Submitted to Sakarya University

Öğrenci Ödevi

<%**1**

4

Kewen Xia, Zhongliang Lv, Kang Liu, Zhenyu Lu, Chuande Zhou, Hong Zhu, Xuanlin Chen. "Global contextual attention augmented YOLO with ConvMixer prediction heads for PCB surface defect detection", Scientific Reports, 2023

Yayın

<%**1**

5

9lib.net

İnternet Kaynağı

<%**1**

6

Submitted to Düzce Üniversitesi

Öğrenci Ödevi

<%**1**

7

Gökkaya, Hasan. "Derin Öğrenme Teknikleri ile Anomali İçeren Metal Somunların Hata Tespit ve Sınıflandırılması", Dokuz Eylül Üniversitesi (Turkey), 2024

Yayın

<%**1**

8

Submitted to Kirikkale University

TEŐEKKÖR

“UYDU VE İHA VERİLERİYLE DESTEKLENEN KATMANLI ORMAN YANGINI ALGILAMA SİSTEMİ” konulu alıőma Fırat Üniversitesi Bilgisayar Mühendislięi Bölümünde 2025-2026 yılı bahar döneminde bitirme projesi olarak hazırlanmıştır.

alıőma süremiz boyunca yardımlarını esirgemeyen değerli hocamız Do. Dr. Ahmet INAR’a alıőmalarımızda bize yardımcı olduęu için teşekkürlerimizi sunarız.

İÇİNDEKİLER

	<u>Sayfa No</u>
İÇİNDEKİLER	I
ŞEKİLLER LİSTESİ.....	III
TABLolar LİSTESİ.....	IV
KISALTMALAR	V
ÖZET	VI
ABSTRACT	VII
1. GİRİŞ	1
2. LİTERATÜR TARAMASI	2
3. MATERYAL VE METOT	4
3.1. Veri Seti Hazırlığı.....	4
3.1.1. Uydu Görüntüleri Veri Seti.....	4
3.1.2. İHA Görüntüleri Veri Seti	5
3.2. Yöntem Seçimi: Neden Nesne Tespiti (Object Detection).....	5
3.3. Önerilen Sistem Mimarisi ve İş Akışı.....	6
3.3.1. Katman 1: Hotspot Tetikleme ve İzleme (NASA FIRMS/VIIRS)	7
3.3.2. Katman 2: Uydu Tabanlı Doğrulama ve Yapay Zeka Destekli Tespit	7
3.3.3. Katman 3: İHA Tabanlı Doğrulama (Fallback Mekanizması)	8
3.3.4. Katman 4: Alarm, Kayıt ve Bildirim Katmanı	8
3.4. Kullanılan Derin Öğrenme Modelleri	9
3.4.1. YOLOv8.....	9
3.4.2. YOLOv10.....	9
3.4.3. YOLOv12.....	9
3.5. Eğitim Konfigürasyonu ve Hiperparametreler	9
3.5.1. Uydu Katmanı Eğitim Stratejileri ve Hiperparametreler	10
3.5.2. Model Mimarilerinin Karşılaştırılması (YOLOv8, v10, v12)	10
3.5.3. Spektral Bant Performans Analizleri (YOLOv10s)	10

3.5.4. İHA Katmanı Eğitim Stratejisi ve Hiperparametreler	11
4. BULGULAR	12
4.1. Uydu Görüntülerinde Model ve Spektral Performans Analizi	12
4.1.1. YOLO Mimarilerinin Performans Karşılaştırması.....	12
4.1.2. Görsel Tespit Analizi (Dahili ve Harici Testler).....	15
4.1.3. YOLOv10 Modelinin Spektral Bant Performans Analizi	17
4.1.4. Sayısal Performans Değerlendirmesi	17
4.1.5. Görsel Tespit Analizi.....	19
4.2. İHA Katmanında Model Performans Karşılaştırması.....	20
4.2.1. YOLO Mimarilerinin Performans Karşılaştırması.....	20
4.2.2. Gerçek Zamanlı Hız ve Gecikme Analizi	22
4.2.3. Görsel Analiz ve Model Karşılaştırması	23
4.2.4. Test Veri Seti Üzerindeki Başarım	23
4.2.5. Harici Veriler ve Genelleştirme Testi	24
4.3. Genel Değerlendirme ve Model Seçimi	25
5. SONUÇ VE TARTIŞMA	27
5.1. Sonuçlar.....	27
5.2. Tartışma.....	28
5.2.1. Gelecek Çalışmalar ve Öneriler	28
KAYNAKLAR	30
ÖZGEÇMİŞ.....	32

ŞEKİLLER LİSTESİ

	<u>Sayfa No</u>
Şekil 3.1. Önerilen Sistemin Katmanlı Mimarisi ve İş Akış Diyagramı.....	7
Şekil 4.1. Uydu Veri Seti Üzerinde YOLO Modellerinin mAP@0.5:0.95 Karşılaştırması	13
Şekil 4.2. Uydu Veri Seti Üzerinde Modellerinin F1-Güven (F1-Confidence) Eğrileri.....	13
Şekil 4.3. Uydu Veri Seti Üzerinde YOLOv10s Modeline Ait Karmaşıklık Matrisi (Confusion Matrix) Analizi	14
Şekil 4.4. Dahili Test Veri Seti (Urban False Color) Üzerinde Modellerin Tespit Başarısı	16
Şekil 4.5. Harici Test Veri Seti (SWIR) Üzerinde Modellerin Tespit Başarısı.....	17
Şekil 4.6. Spektral Bant Performanslarının Isı Haritası.....	18
Şekil 4.7. Aynı Yangın Sahnesinin Farklı Spektral Bantlardaki Tespit Skorları.....	19
Şekil 4.8. İHA Veri Seti Üzerinde YOLO Modellerinin mAP@0.5:0.95 Karşılaştırması	20
Şekil 4.9. İHA Veri Seti Üzerinde Modellerinin F1-Güven (F1-Confidence) Eğrileri	21
Şekil 4.10. İHA Veri Seti Üzerinde YOLOv12s Modeline Ait Karmaşıklık Matrisi (Confusion Matrix) Analizi	22
Şekil 4.11. Dahili Test Veri Seti Üzerinde Modellerin Tespit Başarısı.....	24
Şekil 4.12. Harici Veri Seti Üzerinde Modellerin Tespit Başarısı.....	25

TABLÖLAR LİSTESİ

	<u>Sayfa No</u>
Tablo 3.1. Spektral Kompozitlere Göre Uydu Veri Kümesinin Dağılımı.....	5
Tablo 3.2. İHA Veri Seti Dağılımı	5
Tablo 3.3. Model Performans Karşılaştırma Testleri Eğitim Ayarları (v8, v10, v12)	10
Tablo 3.4. Spektral Bant Analiz Testleri Eğitim Ayarları (Her Bant İçin Ayrı Uygulanmıştır)	11
Tablo 3.5. İHA Katmanı Modelleri Eğitim Parametreleri	11
Tablo 4.1. Uydu Veri Seti Üzerinde YOLO Modellerinin Performans Karşılaştırması	12
Tablo 4.2. YOLOv10s Modelinin Farklı Spektral Bantlardaki Performansı	18
Tablo 4.3. İHA Veri Seti Üzerinde YOLO Modellerinin Performans Karşılaştırması	20
Tablo 4.4. İHA Katmanı: Modellerin İşlem Süreleri ve FPS Değerleri.....	23

KISALTMALAR

AOI	: Area of Interest (İlgi Alanı)
CNN	: Convolutional Neural Network (Evrişimli Sinir Ağı)
COCO	: Common Objects in Context (Yaygın Nesne Veri Seti)
FPS	: Frames Per Second (Saniye Başına Kare Sayısı)
İHA	: İnsansız Hava Aracı
mAP	: mean Average Precision (Ortalama Hassasiyet Değeri)
NMS	: Non-Maximum Suppression (Maksimum Olmayanların Bastırılması)
RGB	: Red, Green, Blue (Kırmızı, Yeşil, Mavi-Görünür Işık)
SWIR	: Short-Wave Infrared (Kısa Dalga Boylu Kızılötesi)
UAV	: Unmanned Aerial Vehicle (İnsansız Hava Aracı)
VIIRS	: Visible Infrared Imaging Radiometer Suite (Görünür Kızılötesi Görüntüleme)
YOLO	: You Only Look Once

ÖZET

Orman yangınlarının erken aşamada tespit edilmesi ve güvenilir biçimde doğrulanması, can kayıplarının önlenmesi ile ekolojik ve ekonomik zararların azaltılması açısından kritik öneme sahiptir. Bu çalışmada, geniş alan kapsama avantajına sahip uydu görüntüleri ile yüksek mekânsal çözünürlük sunan insansız hava araçlarını (İHA) bütünleştiren, çok katmanlı ve yapay zekâ tabanlı otonom bir orman yangını tespit ve doğrulama sistemi önerilmektedir. Önerilen sistemin ilk katmanında, Sentinel-2 uydu verileri kullanılarak farklı YOLO tabanlı derin öğrenme mimarilerinin yangın tespiti performansları karşılaştırmalı olarak analiz edilmiştir. Yapılan deneysel değerlendirmeler sonucunda, hesaplama verimliliği, hız ve doğruluk dengesi açısından YOLOv10s modeli, uydu tabanlı ön tarama ve erken uyarı aşaması için en uygun mimari olarak belirlenmiştir. Spektral bant analizleri kapsamında True Color, False Color, SWIR ve Urban False Color kompozitleri incelenmiş; Urban False Color kombinasyonunun, özellikle duman altında kalan ısı kaynaklarının ayrıştırılmasında ve yanlış pozitif oranlarının azaltılmasında diğer bantlara kıyasla daha başarılı sonuçlar sunduğu gözlemlenmiştir. Sistemin ikinci katmanında, uydu verilerinin yetersiz kaldığı veya tespit sonuçlarının belirsizlik içerdiği durumlar için İHA tabanlı doğrulama mekanizması devreye alınmaktadır. Bu aşamada, karmaşık zemin koşullarında daha yüksek hassasiyet sağlayan YOLOv12s modeli kullanılarak, yüksek çözünürlüklü İHA görüntüleri üzerinde detaylı yangın analizi gerçekleştirilmektedir. Ayrıca, yangınla karıştırılabilecek nesnelerin “Other” sınıfı altında modellenmesi sayesinde, özellikle karmaşık zemin koşullarında modelin sınıflandırma doğruluğu artırılmış ve yanlış pozitif tespitlerin azaltılması sağlanmıştır. Önerilen hibrit yaklaşım sayesinde, kesin uydu tespitlerinin bulunduğu senaryolarda doğrudan müdahale birimlerinin bilgilendirilmesi sağlanırken, belirsiz durumlarda yalnızca gerekli bölgeler için İHA yönlendirilerek gereksiz operasyonların önüne geçilmektedir. Böylece sistemin genel enerji verimliliği, operasyonel maliyeti ve karar alma hızı optimize edilerek, gerçek zamanlı erken uyarı sistemleri için ölçeklenebilir ve güvenilir bir çözüm sunulmaktadır.

Anahtar Kelimeler: Orman Yangını Tespiti, Derin Öğrenme, Sentinel-2, İHA, YOLOv8s, YOLOv10s, YOLOv12s, Spektral Analiz, Urban False Color, Erken Uyarı Sistemleri.

ABSTRACT

Early detection and reliable verification of forest fires are of critical importance for preventing loss of life and minimizing ecological and economic damage. In this study, a multi-layered, artificial intelligence based autonomous forest fire detection and verification system is proposed, integrating satellite imagery with wide-area coverage capabilities and unmanned aerial vehicles (UAVs) providing high spatial resolution. In the first layer of the proposed system, the fire detection performances of different YOLO-based deep learning architectures are comparatively analyzed using Sentinel-2 satellite data. Based on experimental evaluations, the YOLOv10s model is identified as the most suitable architecture for satellite-based pre-screening and early warning stages, offering a balanced trade-off between computational efficiency, processing speed, and detection accuracy. Within the scope of spectral band analysis, True Color, False Color, SWIR, and Urban False Color composites are examined. The Urban False Color combination is observed to provide superior performance compared to other composites, particularly in distinguishing heat sources obscured by smoke and in reducing false positive detection rates. In the second layer of the system, a UAV-based verification mechanism is activated in cases where satellite data are insufficient or detection results contain uncertainty. At this stage, detailed fire analysis is conducted on high-resolution UAV imagery using the YOLOv12s model, which offers higher sensitivity under complex terrain conditions. Furthermore, by modeling fire-confusable objects under an “Other” class, the classification accuracy of the model is enhanced, especially in complex ground scenarios, leading to a significant reduction in false positive detections. Through the proposed hybrid approach, direct notification of response units is enabled in scenarios with confirmed satellite detections, while in uncertain cases, UAVs are deployed only to the necessary regions, thereby preventing unnecessary operations. Consequently, the system optimizes overall energy efficiency, operational cost, and decision-making speed, providing a scalable and reliable solution for real time early warning systems.

Keywords: Forest Fire Detection, Deep Learning, Sentinel-2, UAV, YOLOv8s, YOLOv10s, YOLOv12s, Spectral Analysis, Urban False Color, Early Warning Systems.

1. GİRİŞ

Küresel iklim değişikliği ve artan kuraklık koşulları, orman yangınlarının sıklığını ve etkisini önemli ölçüde artırmaktadır [1, 2]. Bu durum, orman ekosistemleri üzerinde geri döndürülemez çevresel ve ekonomik kayıplara yol açmakta ve yangınlarla mücadelede erken tespitin kritik önemini ortaya koymaktadır [1, 3]. Ancak geleneksel gözetleme yöntemleri, geniş ormanlık alanlarda sürekli ve tam kapsama sağlayamamakta, bu durum erken müdahale süreçlerini olumsuz etkilemektedir [2,4].

Uzaktan algılama teknolojileri, orman yangınlarının erken tespitinde önemli bir alternatif olarak öne çıkmaktadır [3, 5]. Uydu sistemleri, geniş alanları düzenli aralıklarla izleyebilme avantajına sahip olmakla birlikte, mekânsal çözünürlük sınırlamaları ve atmosferik koşullar nedeniyle tek başına yeterli doğruluk sağlayamayabilmektedir [6,7]. İHA ise alçak irtifadan elde edilen yüksek çözünürlüklü görüntülerle ayrıntılı analiz imkânı sunmasına rağmen, batarya ve menzil kısıtları sebebiyle geniş alanların sürekli izlenmesinde sınırlı kalmaktadır [8, 9]. Bu nedenle, her iki teknolojinin birbirini tamamlayacak şekilde birlikte ele alınması gerekmektedir [10].

Derin öğrenme alanında yaşanan gelişmeler, özellikle uzaktan algılama görüntülerinin analizinde kullanılan nesne tespit yaklaşımlarının orman yangını tespitinde etkin biçimde kullanılmasına olanak sağlamıştır [11–13]. Ancak orman ortamlarında bulunan bulutlar, sıcak yüzeyler ve benzer spektral özellikler gösteren doğal yapılar, yanlış alarm oranlarının artmasına neden olabilmektedir [3,14]. Literatürde, bu tür problemlerin azaltılmasına yönelik olarak veri seti tasarımı ve model eğitimi stratejilerinin önemli olduğu vurgulanmaktadır [4, 15].

Bu çalışmada, uydu ve İHA katmanlarından oluşan, derin öğrenme tabanlı iki aşamalı bir orman yangını tespit yaklaşımı ele alınmıştır. Uydu katmanında multispektral uydu görüntüleri kullanılarak eğitilen YOLO tabanlı modellerin geniş alanlardaki yangın tespit performansları değerlendirilmiştir [16, 17]. İHA katmanında ise yüksek çözünürlüklü görüntüler üzerinde eğitilen modeller ile yangın bölgelerinin doğrulanmasına yönelik bir yaklaşım incelenmiştir [18, 19]. Çalışma kapsamında, her iki katman için farklı YOLO mimarilerinin performansları karşılaştırılarak yanlış alarm oranları analiz edilmiştir [5, 15].

2. LİTERATÜR TARAMASI

Orman yangınlarının erken aşamada tespit edilmesi problemi, literatürde uzun yıllardır ele alınmakta olup hem geleneksel hem de uzaktan algılamaya dayalı çeşitli yöntemler önerilmiştir [5,4]. Geleneksel yaklaşımlar; gözetleme kuleleri, insanlı devriyeler ve yer tabanlı sensör ağları gibi yöntemlere dayanmaktadır [2, 20]. Bu yöntemler, düşük kurulum maliyetleri ve basit altyapıları nedeniyle tercih edilse de, geniş orman alanlarında kör noktaların oluşması ve sürekli insan kaynağı gereksinimi nedeniyle etkinliklerini kaybetmektedir [2,14]. Ayrıca, bu sistemlerin 7/24 kesintisiz izleme ihtiyacını karşılayamaması, erken müdahale süreçlerini doğrudan olumsuz etkilemektedir [4,21].

Bu sınırlamaların aşılması amacıyla uzaktan algılama tabanlı yaklaşımlar literatürde giderek daha fazla ön plana çıkmıştır [3, 5]. Uydu görüntüleri, geniş alanları kapsayabilme yetenekleri sayesinde orman yangını tespitinde önemli bir alternatif sunmaktadır [1,22]. Özellikle MODIS ve VIIRS gibi sensörler, termal ve orta kızılötesi bantlar üzerinden sıcaklık anomalilerini algılayarak yangın başlangıçlarını tespit edebilmekte ve küresel ölçekte operasyonel olarak kullanılmaktadır [6,7,21]. Bununla birlikte, bu tür uydu sistemleri mekânsal çözünürlük kısıtları ve atmosferik koşullara (bulut, duman ve sis) karşı duyarlılıkları nedeniyle yanlış alarm üretmeye yatkın olup, özellikle küçük ölçekli veya duman altındaki yangınların tespitinde yetersiz kalabilmektedir [3,23,24]. Bu durum, uydu tabanlı sistemlerin tek başına güvenilir bir doğrulama mekanizması sunmasını zorlaştırmaktadır [5,10].

Uydu verilerinin bu sınırlılıklarını gidermek amacıyla, insansız hava araçları (İHA) tabanlı çözümler literatürde tamamlayıcı bir yaklaşım olarak değerlendirilmektedir [9,18]. İHA'lar, alçak irtifadan elde edilen yüksek çözünürlüklü görüntüler sayesinde yangın bölgelerinin doğrulanması ve detaylı incelenmesi açısından önemli avantajlar sunmaktadır [8,13]. Özellikle karmaşık zemin koşullarında ve küçük yangın başlangıçlarının tespitinde İHA tabanlı sistemlerin daha başarılı olduğu rapor edilmiştir [19, 25]. Ancak sınırlı batarya ömrü, menzil kısıtları ve geniş alanların sürekli izlenmesine uygun olmamaları, İHA'ların tek başına kapsamlı bir erken uyarı sistemi olarak kullanılmasını zorlaştırmaktadır [9, 26]. Bu nedenle, uydu ve İHA gibi farklı algılama platformlarının birlikte ele alındığı hibrit sistem yaklaşımlarının önemi literatürde giderek artmaktadır [10,26].

Son yıllarda görüntü işleme ve yapay zekâ alanındaki gelişmelerle birlikte, derin öğrenme tabanlı yöntemler orman yangını tespitinde yaygın biçimde kullanılmaya başlanmıştır [11,12,27]. Özellikle Evrişimli Sinir Ağları (CNN), karmaşık görsel örüntüleri öğrenebilme yetenekleri sayesinde yangın ve duman tespiti problemlerinde geleneksel yöntemlere kıyasla daha yüksek başarı sağlamaktadır [11,25]. Literatürde, yangın tespiti amacıyla görüntü sınıflandırma, semantik

segmentasyon ve nesne tespiti tabanlı farklı yaklaşımlar önerilmiştir [4,28]. Görüntü sınıflandırma yöntemleri, bir görüntüde yangın varlığını belirleyebilse de, yangının konumsal bilgisini sunamaması nedeniyle operasyonel müdahale süreçleri için sınırlı kalmaktadır [12,29]. Bu nedenle, yangının konumunu sınırlayıcı kutular (bounding box) ile belirleyebilen nesne tespiti tabanlı yöntemlerin gerçek zamanlı ve otonom sistemler için daha uygun olduğu ifade edilmektedir [28,29].

Bu bağlamda, tek aşamalı nesne tespiti mimarileri arasında yer alan YOLO (You Only Look Once) ailesi, yüksek işlem hızı ve yeterli doğruluk dengesi sunması nedeniyle yangın tespit çalışmalarında sıklıkla tercih edilmektedir [30,31]. YOLOv3 ile birlikte uzaktan algılama görüntülerinde yaygınlaşmaya başlayan bu mimari, sonraki sürümlerle birlikte hem doğruluk hem de gecikme süresi açısından önemli iyileştirmeler sunmuştur [32,16]. Literatürde YOLOv3, YOLOv5 ve YOLOv8 gibi sürümlerin hem uydu hem de İHA görüntüleri üzerinde başarılı şekilde uygulandığı ve gerçek zamanlı sistemler için uygun sonuçlar verdiği rapor edilmiştir [13,16,17,33]. Ancak orman ortamlarında sıklıkla karşılaşılan bulutlar, parlak yüzeyler, kızıl kayalıklar ve yüksek sıcaklığa sahip zeminler, YOLO tabanlı modellerin yanlış pozitif (false positive) üretmesine neden olabilmektedir [3, 14]. Bu problemi azaltmak amacıyla, veri seti çeşitliliğinin artırılması, zor örneklerin (hard negatives) modele dahil edilmesi ve çok bantlı (multi-spektral) görüntülerin kullanılması literatürde önerilen temel stratejiler arasında yer almaktadır [4,34,15].

Literatürdeki çalışmalar genel olarak değerlendirildiğinde, uydu sistemlerinin geniş alan kapsama avantajına, İHA'ların ise yüksek çözünürlüklü doğrulama kabiliyetine sahip olduğu açıkça görülmektedir [5, 10]. Bununla birlikte, bu iki platformun çoğunlukla birbirinden bağımsız şekilde ele alındığı ve bütünleşik bir mimari içerisinde sistematik olarak değerlendirildiği çalışmaların sınırlı sayıda olduğu dikkat çekmektedir [26]. Ayrıca, birçok çalışmada tek bir derin öğrenme mimarisi veya tek bir görüntü türü üzerinden analiz yapılmış, farklı model ve veri kombinasyonlarının karşılaştırmalı etkileri yeterince incelenmemiştir [4,15].

Bu tez çalışması, literatürde tespit edilen bu boşluğu hedefleyerek, uydu ve İHA verilerini birlikte ele alan kavramsal bir hibrit yangın algılama ve doğrulama sistemi sunmaktadır. Çalışma kapsamında, çok bantlı Sentinel-2 uydu görüntülerinden oluşturulan veri setleri üzerinde YOLOv8s, YOLOv10s ve YOLOv12s mimarileri karşılaştırmalı olarak eğitilmiş; benzer şekilde İHA tabanlı görüntüler üzerinde de aynı mimariler analiz edilmiştir [35,36,37].

3. MATERYAL VE METOT

Bu bölümde, orman yangınlarının erken tespiti amacıyla tasarlanan otonom sistemin teknik altyapısı, kurgulanan veri setleri, yöntem seçiminin gerekçeleri ve model eğitim stratejileri detaylandırılmıştır. Çalışma, uydu tabanlı makro tespit ve İHA tabanlı mikro doğrulama olmak üzere iki ana katmanlı bir mimari önerisi üzerine kurulmuştur.

3.1. Veri Seti Hazırlığı

Derin öğrenme modellerinin başarısı, doğrudan kullanılan verinin kalitesine ve sınıf dağılımına bağlıdır [4, 15]. Bu çalışmada, modelin genelleme yeteneğini artırmak amacıyla hem uydu hem de İHA perspektifinden özelleştirilmiş iki farklı veri seti yapısı kurgulanmıştır.

3.1.1. Uydu Görüntüleri Veri Seti

Bu çalışmada, derin öğrenme modellerinin genelleştirme yeteneğini artırmak ve orman yangını tespit sistemlerinde sıkça karşılaşılan yanlış alarm problemini minimize etmek amacıyla, pozitif ve negatif örneklerden oluşan hibrit bir veri seti kurgulanmıştır [3, 14]. Veri setinin temel kurgusu; modelin yalnızca yangın özniteliklerini öğrenmesini sağlamakla kalmayıp, aynı zamanda yangınla karıştırılabilecek spektral yanılsamaları da ayırt edebilmesini hedeflemektedir.

Pozitif Veri Kümesi: Yangın içeren görüntüler, Sentinel-2 uydu misyonundan elde edilen veriler temel alınarak Roboflow platformu üzerinden temin edilmiştir [35]. Yaklaşık 9.879 adet görüntüden oluşan bu küme; yangın, duman ve yanmış alanların farklı atmosferik koşullarda modellenmesini sağlayan True Color, False Color, SWIR ve Urban False Color spektral bant kombinasyonlarını içermektedir [34, 24].

Negatif Veri Kümesi ve Üretim Süreci: Negatif veri kümesi, pozitif verilerle sensör tipi, spektral bant yapısı ve mekânsal çözünürlük açısından tam uyum sağlaması amacıyla tamamen bu çalışma kapsamında özgün olarak üretilmiştir. Üretim sürecinde Sentinel-2 L2A ürünleri kullanılmış; Google Colab ortamında geliştirilen özel Python betikleri ve SentinelHub API entegrasyonu ile yangın içermeyen ancak orman, tarım arazisi ve kentsel alanları kapsayan görüntüler elde edilmiştir [7, 21]. Modelin sınıf dengesizliğinden kaynaklanan öğrenme problemleri yaşamaması adına, negatif örnek sayısı (9.130), pozitif örnek sayısına (9.879) yakın tutulmuştur [15].

Veri Ön İşleme ve Filtreleme: Veri setinin kalitesini korumak adına görüntüler üzerinde yapay iyileştirme uygulanmamış, bunun yerine filtreleme temelli bir strateji izlenmiştir. Aşırı karanlık, doku bilgisi içermeyen veya tamamen kapalı sahneler veri setinden çıkarılmıştır.

Bununla birlikte, modelin bulut ve duman gibi zorlayıcı koşulları öğrenebilmesi amacıyla parçalı bulutlu sahneler bilinçli olarak veri setinde korunmuştur [4, 14].

Elde edilen toplam 19.009 görüntünün spektral kompozitlere ve veri kümelerine (Eğitim, Doğrulama, Test) göre dağılımı Tablo 3.1’te sunulmuştur.

Tablo 3.1. Spektral Kompozitlere Göre Uydu Veri Kümesinin Dağılımı

Spektral Kompozit	Train	Validation	Test	Toplam
Urban False Color	4.204	813	341	5.358
SWIR	4.132	754	362	5.248
True Color	2.438	402	248	3.088
False Color	4.261	797	257	5.315
GENEL TOPLAM	15.035	2.769	1.208	19.009

3.1.2. İHA Görüntüleri Veri Seti

İHA katmanı için tek bir kaynağa bağlı kalmak yerine, literatürdeki açık kaynaklı veri setleri taranmış ve farklı irtifa ve ışık koşullarını içeren hibrit bir veri havuzu oluşturulması yoluna gidilmiştir [9, 18]. Bu kapsamda, yaklaşık 21.200 görüntü içeren birincil veri seti ile 6.100 görüntü içeren ikincil bir veri seti birleştirilerek toplamda yaklaşık 27.300 görüntülük kapsamlı bir havuz derlenmiştir.

Veri seti oluşturulurken, orman arazilerinde sıkça karşılaşılan ve modelleri yanılgıya düşüren (false positive) güneş yansımaları, kırmızı kayalıklar ve parlak çatılar gibi nesneler özellikle seçilmiştir. Modelin kararlılığını artırmak amacıyla, bu yanıltıcı nesnelerin veri setinde “Other” etiketi altında ayrı bir sınıf olarak etiketlenmesi stratejisi uygulanmıştır [4,15].

Elde edilen birleştirilmiş veri seti, modelin eğitim (train), doğrulama (validation) ve test süreçleri için Tablo 3.2’te belirtilen oranlarda ayrıştırılmıştır.

Tablo 3.2. İHA Veri Seti Dağılımı

Veri Grubu	Görüntü Sayısı
Eğitim Seti	20.100
Doğrulama Seti	4.800
Test Seti	2.400
TOPLAM	27.300

3.2. Yöntem Seçimi: Neden Nesne Tespiti (Object Detection)

Literatürde orman yangını tespiti problemi, görüntü sınıflandırma (image classification) tabanlı yaklaşımlar kullanılarak da ele alınmıştır [11,12,27]. Bu yöntemlerde, bir görüntü içerisinde yangın varlığına ilişkin genel bir karar üretilebilmekte; ancak yangının görüntü

içerisindeki konumuna dair uzamsal bilgi sağlanamamaktadır [4,29]. Bu durum, özellikle müdahale ve yönlendirme gerektiren otonom sistemler için önemli bir kısıt oluşturmaktadır.


Bu çalışmada, otonom İHA navigasyonunun sağlanabilmesi için yangın bölgelerinin piksel koordinatları düzeyinde belirlenmesine ihtiyaç duyulmaktadır [18,19]. Sadece “yangın var/yok” çıktısı üreten sınıflandırma tabanlı modeller, hedef bölgenin konumunu açık biçimde tanımlayamadığı için bu gereksinimi karşılamakta yetersiz kalmaktadır [12,28]. Bu nedenle, yangının konumunu sınırlayıcı kutular (bounding box) aracılığıyla hassas bir şekilde tespit edebilen nesne tespiti (object detection) tabanlı mimarilerin kullanılması tercih edilmiştir [30,28].

Nesne tespiti yaklaşımları, yangının görüntü içerisindeki konumunu, boyutunu ve merkez koordinatlarını eş zamanlı olarak belirleyebilmesi sayesinde, gerçek zamanlı karar verme ve otonom yönlendirme senaryoları için daha uygun bir çözüm sunmaktadır [29,16]. Bu sayede sistemin, tespit edilen yangın bölgesinin merkez koordinatlarını hesaplayarak İHA’yı doğrudan hedef noktaya yönlendirebilmesi mümkün hâle gelmektedir [18,26]. Literatürde de, otonom hava araçları ile entegre çalışan erken yangın tespit sistemlerinde nesne tespiti tabanlı yaklaşımların sınıflandırma yöntemlerine kıyasla daha işlevsel olduğu rapor edilmiştir [13,19,10].

3.3. Önerilen Sistem Mimarisi ve İş Akışı

Bu çalışmada önerilen orman yangını erken uyarı sistemi, dört ana katmandan oluşan modüler ve döngüsel bir mimari üzerine inşa edilmiştir. Tasarlanan mimari yapı; uydu tabanlı ön tetikleme, yapay zeka destekli doğrulama ve çoklu veri kaynağına dayalı karar mekanizmalarını bir araya getirerek, erken aşama yangınların güvenilir şekilde tespit edilmesini ve yanlış alarmların minimize edilmesini amaçlamaktadır.

Sistemin katmanlı yapısı ve veri akış diyagramı Şekil 3.1’de sunulmuştur.



Şekil 3.1. Önerilen Sistemin Katmanlı Mimarisi ve İş Akış Diyagramı

3.3.1. Katman 1: Hotspot Tetikleme ve İzleme (NASA FIRMS/VIIRS)

Sistemin birinci katmanı, enerji verimliliğini sağlayan ön tetikleyici ve izleme bileşeni olarak görev yapmaktadır. Bu katmanda sistem, sürekli görüntü işleme yapmak yerine, NASA FIRMS ve VIIRS servislerini periyodik olarak (örneğin 5–10 dakikalık aralıklarla) sorgulayarak, önceden tanımlanmış İlgi Alanı (AOI - Area of Interest) içerisinde yeni bir termal hotspot (sıcak nokta) kaydı olup olmadığını kontrol etmektedir.

Eğer AOI içerisinde yeni bir hotspot tespit edilmezse, sistem herhangi bir ağır işlem gerçekleştirmeden bekleme modunda izleme döngüsüne devam eder. Ancak yeni bir hotspot kaydı tespit edildiğinde, ilgili koordinat ve zaman bilgisi sistemin ikinci katmanına aktarılarak detaylı doğrulama süreci başlatılır. Bu yapı sayesinde sistem, geniş ormanlık alanları sürekli ve düşük maliyetle izleyebilen bir ön filtre mekanizması kazanmaktadır.

3.3.2. Katman 2: Uydu Tabanlı Doğrulama ve Yapay Zeka Destekli Tespit

İkinci katman, önerilen mimarinin ana karar ve analiz merkezidir. Birinci katmandan gelen tetikleme sinyali sonrası sistem, ilgili koordinat için SentinelHub altyapısı üzerinden” neredeyse gerçek zamanlı” (near real-time) Sentinel-2 uydu görüntüsü talep eder.

Görüntüleme aşamasında, bu çalışma kapsamında gerçekleştirilen spektral analizler (Bölüm 4.1.2) doğrultusunda, duman altı ısıyı en iyi ayırt eden Urban False Color spektral kompoziti kullanılmaktadır. Elde edilen görüntü yaması, orman yangını tespiti amacıyla optimize edilmiş ve eğitilmiş YOLOv10s nesne algılama modeline girdi olarak verilir.

- Model yangın tespit ederse: Olay “Uydu ile Doğrulanmış Yangın” olarak kabul edilir ve alarm mekanizmasına (Katman 4) iletilir.
- Model yangın tespit etmezse: Kayıt “Yanlış Alarm” olarak değerlendirilir ve sistem Katman 1’deki izleme döngüsüne döner.

Ancak, Sentinel-2 verisinin aşırı bulutluluk, uydu geçiş zamanı kısıtları veya veri erişim problemleri nedeniyle temin edilemediği durumlarda sistem, doğrulama işlemini gerçekleştirebilmek adına üçüncü katmana geçiş yapar.

3.3.3. Katman 3: İHA Tabanlı Doğrulama (Fallback Mekanizması)

Üçüncü katman, uydu verisinin yetersiz kaldığı veya belirsiz olduğu durumlar için tasarlanmış tamamlayıcı bir “Yedek (Fallback)” doğrulama katmanıdır. Bu katman, yalnızca Sentinel-2 görüntüsünün analiz için uygun olmadığı senaryolarda devreye girerek gereksiz İHA uçuşlarını engeller.

Bu aşamada sistem, ilgili hotspot koordinatına en yakın İHA istasyonunu belirleyerek otonom bir görev emri oluşturur. Bölgeye intikal eden İHA’dan elde edilen yüksek çözünürlüklü görüntüler, gömülü sistemler üzerinde çalışan ve küçük nesneleri tespit etmede yüksek başarı gösteren YOLOv12s modeli ile analiz edilir.

- İHA görüntüleri üzerinde yangın tespit edilirse, olay kesinleşmiş kabul edilir ve alarm üretilir.
- Tespit yapılmazsa, sistem bekleme moduna geçer.

3.3.4. Katman 4: Alarm, Kayıt ve Bildirim Katmanı

Dördüncü katman, sistemin çıktı ve müdahale arayüzüdür. Uydu (Katman 2) veya İHA (Katman 3) tarafından doğrulanan yangın vakaları bu katmana iletilir. Olay; tespit zamanı, tam koordinat, tespit eden kaynak (Uydu/İHA) ve güven skoru bilgileriyle birlikte veritabanına kaydedilir. Eş zamanlı olarak yetkili birimlere (Orman Genel Müdürlüğü, İtfaiye vb.) görsel kanıtları içeren bir alarm bildirimi gönderilir.

3.4. Kullanılan Derin Öğrenme Modelleri

Çalışmada, gerçek zamanlı nesne tespiti için literatürdeki en güncel YOLO mimarileri (v8, v10, v12) ele alınmış ve her iki katman (Uydu ve İHA) için ayrı ayrı test edilmiştir.

3.4.1. YOLOv8

Ultralytics tarafından geliştirilen YOLOv8, anchor-free yapısı ve kararlı tespit yeteneği sayesinde, hız ve doğruluk dengesi açısından referans bir mimari olarak test süreçlerine dahil edilmiştir [33].

3.4.2. YOLOv10

NMS (Non-Maximum Suppression) aşamasını ortadan kaldıran uçtan uca (end-to-end) mimarisi ve düşük gecikme süresi (low latency) özellikleri nedeniyle, özellikle hızın kritik olduğu uydu katmanı testlerinde değerlendirilmiştir [36].

3.4.3. YOLOv12

Dikkat mekanizması (attention mechanism) odaklı yapısı sayesinde karmaşık zeminlerde ve orman örtüsü altında küçük ölçekli nesneleri tespit etme potansiyeline sahip olması nedeniyle, hassas doğrulama gerektiren İHA katmanı testlerine dahil edilmiştir [37].

3.5. Eğitim Konfigürasyonu ve Hiperparametreler

Bu çalışmada geliştirilen derin öğrenme modellerinin eğitiminde, ağırlıkların rastgele başlatıldığı sıfırdan öğrenme (training from scratch) yaklaşımı yerine, literatürde başarısı kanıtlanmış transfer öğrenme (transfer learning) yöntemi benimsenmiştir [38].

Transfer öğrenme, büyük ölçekli veri setleri üzerinde eğitilmiş bir modelin edindiği öznitelik çıkarımı yeteneğinin, daha spesifik bir probleme (orman yangını tespiti) aktarılmasını sağlar [39]. Bu kapsamda, çalışmada kullanılan tüm YOLO mimarileri (YOLOv8, YOLOv10 ve YOLOv12), 80 farklı nesne sınıfını içeren geniş kapsamlı COCO veri seti üzerinde önceden eğitilmiş ağırlıklar (pre-trained weights) ile başlatılmıştır [40].

Başlangıç ağırlıkları yüklendikten sonra, modeller hazırlanan multispektral uydu ve yüksek çözünürlüklü İHA veri setleri üzerinde ince ayar (fine-tuning) işlemine tabi tutulmuştur. Bu yaklaşım, modelin duman ve ateş gibi karmaşık dokuları daha hızlı öğrenmesini sağlamış ve sınırlı veri ile yüksek genelleştirme başarısına ulaşılmasına olanak tanımıştır [41]. Modellerin eğitimi, Kaggle platformu üzerinde Tesla T4 GPU donanım hızlandırıcısı kullanılarak gerçekleştirilmiştir.

3.5.1. Uydu Katmanı Eğitim Stratejileri ve Hiperparametreler

Uydu katmanındaki deneyler, “En İyi Model Mimarisi Seçimi” ve “En Verimli Spektral Bant Analizi” olmak üzere iki farklı aşamada gerçekleştirilmiştir. Her iki deney grubu için eğitim stratejileri ve hiperparametreler, amacına uygun olarak ayrı ayrı optimize edilmiştir.

3.5.2. Model Mimarilerinin Karşılaştırılması (YOLOv8, v10, v12)

Sistemin ana omurgasını oluşturacak modelin seçimi amacıyla YOLOv8s, YOLOv10s ve YOLOv12s mimarileri, oluşturulan multispektral uydu veri seti üzerinde eğitilmiştir. Farklı nesne tespiti mimarilerinin aynı veri seti üzerinde karşılaştırmalı olarak değerlendirilmesi, literatürde yaygın olarak kullanılan bir yaklaşım olup model seçiminin nesnel biçimde yapılmasına olanak tanımaktadır [4, 30].

Bu aşamada, modellerin yakınsama (convergence) davranışlarını ayrıntılı biçimde gözlemleyebilmek ve erken durdurma (early stopping) mekanizmasına yeterli esneklik tanımak amacıyla eğitim süresi görece uzun tutulmuştur [41].

Tüm modeller, adil bir kıyaslama ortamı sağlamak adına Tablo 3.3’de sunulan ortak hiperparametre setleri ile 100 epoch boyunca eğitilmiştir.

Tablo 3.3. Model Performans Karşılaştırma Testleri Eğitim Ayarları (v8, v10, v12)

Parametre	Değer	Augmentation	Değer
Başlangıç Ağırlıkları	COCO Pre-trained	Mosaic	1.0
Epochs	100	Mixup	0.0
Patience	20	HSV-Hue	0.015
Batch Size	16	HSV-Saturation	0.7
Image Size	640	HSV-Value	0.4
Optimizer	Auto (AdamW)	Flip (Left-Right)	0.5

3.5.3. Spektral Bant Performans Analizleri (YOLOv10s)

Mimari karşılaştırma testlerinde elde edilen sonuçlar neticesinde (Bölüm 4.1.1), uydu katmanı için en uygun mimarinin YOLOv10s olduğu belirlenmiştir. Bu aşamadan sonra, spektral bantların (True Color, False Color, SWIR ve Urban False Color) yangın tespiti üzerindeki karakteristik etkilerini net bir şekilde ayrıştırabilmek amacıyla dört farklı ve bağımsız eğitim süreci yürütülmüştür [34, 24].

Bu stratejide, tek bir modelin tüm verilerle eğitilmesi yerine, her bir spektral bant için ayrı bir YOLOv10s modeli tahsis edilmiştir. Her model, diğer bantlardan izole edilerek yalnızca ilgili spektral banda ait eğitim setiyle (örneğin; “SWIR Modeli” sadece SWIR görüntüleri ile, “RGB

Modeli” sadece True Color görüntüleri ile) eğitilmiş ve test edilmiştir. Böylece, bantların kendi içindeki öznetelik kalitesi ve yangın ayırt etme gücü bağımsız olarak ölçümlenebilmiştir.

Bu testlerde amaç, mutlak en yüksek skora ulaşmaktan ziyade bantlar arası “bağıl performansı” ölçmek olduğu için, her bir spektral modelin eğitim süresi hesaplama maliyetini düşürmek adına

50 epoch ile sınırlandırılmıştır. Dört farklı spektral modelin eğitiminde de ortak olarak kullanılan konfigürasyon Tablo 3.4’de verilmiştir.

Tablo 3.4. Spektral Bant Analiz Testleri Eğitim Ayarları (Her Bant İçin Ayrı Uygulanmıştır)

Parametre	Değer	Augmentation	Değer
Başlangıç Ağırlıkları	COCO Pre-trained	Mosaic	1.0
Epochs	50	Mixup	0.0
Patience	20	HSV-Hue	0.015
Batch Size	16	HSV-Saturation	0.7
Image Size	640	HSV-Value	0.4
Optimizer	Auto (AdamW)	Flip (Left-Right)	0.5

3.5.4. İHA Katmanı Eğitim Stratejisi ve Hiperparametreler

Bölüm girişinde belirtilen transfer öğrenme metodolojisi, İHA katmanındaki modeller (YOLOv8, YOLOv10 ve YOLOv12) için de uygulanmıştır [38,39]. Ancak İHA görüntülerinin yüksek çözünürlüklü yapısı ve zemin karmaşıklığı nedeniyle, hiperparametrelerde ve veri artırma tekniklerinde bu katmana özgü optimizasyonlar yapılmıştır. Eğitim sürecinde, modellerin küçük ölçekli nesneleri ezberlemeden (overfitting) öğrenebilmesi amacıyla agresif veri artırma yöntemleri olan Mosaic, Mixup ve Copy-Paste teknikleri kullanılmıştır [33,41]. Eğitim 100 epoch boyunca sürdürülmüş ve öğrenme oranı 0.01 olarak belirlenmiştir. Kullanılan hiperparametre seti Tablo 3.5’de sunulmuştur.

Tablo 3.5. İHA Katmanı Modelleri Eğitim Parametreleri

Parametre	Değer	Augmentation	Değer
Başlangıç Ağırlıkları	COCO Pre-trained	Mosaic	1.0
Epochs	100	Mixup	0.15
Batch Size	46	Copy-Paste	0.3
Image Size	640	Scale	0.5
Optimizer	Auto (AdamW)	HSV-Hue	0.015
Learning Rate	0.01	HSV-Saturation	0.7
Patience	15	HSV-Value	0.4
Warmup Epochs	3.0	Flip (Left-Right)	0.5

4. BULGULAR

Bu bölümde, önerilen otonom yangın tespit sisteminin performansı, uydu ve İHA katmanları için ayrı ayrı analiz edilmiştir. Deneysel sonuçlar; Ortalama mAP, Precision, Recall ve bu iki değerin harmonik ortalaması olan F1-Score metrikleri üzerinden değerlendirilmiştir.

4.1. Uydu Görüntülerinde Model ve Spektral Performans Analizi

Sistemin makro analiz katmanını oluşturan uydu modülünde, modellerin tespit başarısı Sentinel-2 uydu görüntüleri üzerinde analiz edilmiştir. Bu bölümde sunulan tüm performans ölçümleri, Bölüm

3.1.1’de (Tablo 3.1) spektral dağılımı ve detayları sunulan test veri seti üzerinde gerçekleştirilmiştir.

4.1.1. YOLO Mimarilerinin Performans Karşılaştırması


Bu çalışmada, geniş alan kapsama yeteneğine sahip uydu tabanlı yangın algılama problemi için seçilen YOLOv8s, YOLOv10s ve YOLOv12s modelleri; birebir aynı eğitim parametreleri, aynı veri kümesi ve eşdeğer donanım altyapısı kullanılarak "adil karşılaştırma" prensibiyle test edilmiştir. Modellerin ayrılan test seti üzerindeki sayısal performans sonuçları Tablo 4.1’de detaylı olarak sunulmuştur.

Tablo 4.1. Uydu Veri Seti Üzerinde YOLO Modellerinin Performans Karşılaştırması


Model	Precision	Recall	F1-Score	mAP@50	mAP@50-95
YOLOv8s	0.822	0.805	0.813	0.855	0.609
YOLOv10s	0.847	0.792	0.819	0.870	0.626
YOLOv12s	0.852	0.776	0.812	0.862	0.614

Tablo 4.1’de elde edilen veriler ışığında, uydu tabanlı erken uyarı sistemlerinin operasyonel gereksinimleri açısından modeller arasında kritik farklar gözlemlenmiştir. Yangın tespit sistemlerinde temel hedef, yangın olaylarını kaçırmamak (yüksek Recall) ile yanlış alarmları minimize etmek (yüksek Precision) arasında optimum bir denge kurmaktır. Bu doğrultuda YOLOv8s modeli, 0.805 ile en yüksek Recall değerine ulaşarak "yangın kaçırma riskinin en düşük olduğu" model olarak öne çıkmıştır. Buna karşın YOLOv12s modeli, 0.852 Precision değeri ile yanlış alarm üretme oranının en düşük olduğu mimari olarak tespit edilmiştir. Ancak, önerilen sistemin hibrit yapısı hem hassasiyet hem de güvenilirlik gerektirmektedir. Bu bağlamda YOLOv10s modeli, 0.819 F1-Skoru ve 0.870 mAP@50 değeri ile diğer iki modelin


avantajlarını dengeleyen en kararlı performansı sergilemiştir. Modelin $mAP@50-95$ metriğinde 0.626 ile en yüksek skora ulaşması, farklı IoU eşik değerlerinde de tespit kararlılığını koruduğunu ve nesne sınırlarını daha doğru belirlediğini kanıtlamaktadır.




Şekil 4.1. Uydu Veri Seti Üzerinde YOLO Modellerinin $mAP@0.5:0.95$ Karşılaştırması



(a) YOLOv8s




(b) YOLOv10s



(c) YOLOv12s

Şekil 4.2. Uydu Veri Seti Üzerinde Modellerinin F1-Güven (F1-Confidence) Eğrileri

Sayısal metriklerin yanı sıra, modellerin eğitim süreçlerindeki öğrenme dinamikleri (training dynamics) Şekil 4.1 ve Şekil 4.2’deki grafikler üzerinden analiz edildiğinde, modellerin yakınsama hızları arasında belirgin farklar tespit edilmiştir. Özellikle YOLOv12s modelinin eğitim eğrisi incelendiğinde, modelin yaklaşık 86. epoch civarında maksimum performans doyumuna ulaşarak çok hızlı bir yakınsama (convergence) sergilediği görülmüştür. Bu durum, YOLOv12s mimarisinin öğrenme hızının yüksek olduğunu ve daha düşük hesaplama maliyetleri ile eğitilebileceğini göstermektedir. Buna karşın YOLOv8s ve YOLOv10s modelleri, öğrenme sürecini 100 epoch sonuna kadar sürdürerek daha kademeli bir gelişim izlemiştir. Bu çalışma kapsamında tasarlanan sistem; uydu tetiklemesi sonrası İHA ile doğrulama yapan çok aşamalı bir yapıya sahiptir. Bu nedenle, sadece eğitim hızı değil, asıl olarak yanlış alarm ve tespit başarısı arasındaki denge (F1 dengesi) operasyonel başarı için belirleyicidir. Sonuç olarak, hem yüksek mAP değerleri sunan hem de kaynak kullanımını optimize eden YOLOv10s modelinin, bu sistemin uydu katmanı için en uygun ve güvenilir mimari olduğu sonucuna varılmıştır.



Şekil 4.3. Uydu Veri Seti Üzerinde YOLOv10s Modeline Ait Karmaşıklık Matrisi (Confusion Matrix) Analizi

Şekil 4.3’te sunulan YOLOv10s modeline ait karmaşıklık matrisi (confusion matrix), modelin sınıflandırma başarımını sayısal olarak doğrulamaktadır. Matris incelendiğinde, modelin 2457 adet yangın örneğini doğru etiketleyerek (True Positive) yüksek bir tespit hassasiyetine ulaştığı görülmektedir. Uydu görüntülerinde yeryüzü yansımalarının yangınla karıştırılması sık karşılaşılan bir problem olmasına rağmen, modelin 666 adet yanlış alarm (False Positive) ile bu oranı makul bir seviyede tuttuğu anlaşılmaktadır. Ayrıca, gözden kaçırılan yangın sayısının (False Negative) 573 olarak gerçekleşmesi, modelin "tespit" ve "yanlış alarm" dengesini başarıyla


kurduğunu göstermektedir. Bu dağılım, YOLOv10s mimarisinin karmaşık uydu verileri üzerinde sadece yüksek doğruluk sağlamakla kalmayıp, aynı zamanda kararlı bir genelleştirme yeteneğine sahip olduğunu kanıtlamaktadır.

4.1.2. Görsel Tespit Analizi (Dahili ve Harici Testler)

Sadece sayısal metriklerin başarımı ölçmekte yeterli olmayacağı düşüncesiyle, model çıktılarının niteliksel olarak da değerlendirilmesi hedeflenmiştir. Bu kapsamda hem dahili test setindeki görüntüleri hem de modelin genelleştirme yeteneğinin sınırlarını zorlayan harici uydu görüntüleri üzerinde detaylı bir görsel analiz süreci yürütülmüştür.

Dahili Test Seti Analizi (Urban False Color): Şekil 4.4'te sunulan görsellerde, duman yoğunluğunun yüksek olduğu sahnelerde ısı kaynaklarını (parlak turuncu) netleştiren Urban False Color bandı kullanılmıştır.

- YOLOv8s (a) ve YOLOv12s (b), yangını tespit etmekte başarılı olsalar da, aynı yangın odağı üzerinde çok sayıda örtüşen sınır kutusu üreterek konumsal bir kararsızlık sergilemişlerdir. Bu durum, hedef koordinat üretiminde sapmalara yol açabilir.
- YOLOv10s (c) ise mimarisinin getirdiği avantajla, dağınık yangın odaklarını daha bütüncül ve tekil çerçevelerle tespit etmiştir. Bu kararlı yapı, multispektral verilerde yanlış alarmları elelediğini ve İHA yönlendirmesi için daha temiz koordinatlar sağladığını kanıtlamaktadır.



Şekil 4.4. Dahili Test Veri Seti (Urban False Color) Üzerinde Modellerin Tespit Başarısı

Harici Veri Analizi (SWIR): Sistemin gerçek saha koşullarındaki performansını simüle etmek amacıyla, eğitim veri setinde bulunmayan farklı bir coğrafyaya ait Sentinel-2 görüntüsü üzerinde testler yapılmıştır (Şekil 4.5). Bu test, model seçimi için belirleyici bir rol oynamıştır.

Görseller incelendiğinde;

- YOLOv8s (a) ve YOLOv12s (b) modelleri, ana yangın odağını sırasıyla 0.71 ve 0.61 güven skorları ile tespit etmiştir.
- YOLOv10s (c) modeli ise aynı yangın odağını 0.79 gibi rakiplerinden belirgin şekilde daha yüksek bir güven skoruyla tespit etmeyi başarmıştır.

Bilinmeyen veriler üzerindeki bu yüksek başarı, YOLOv10s modelinin genelleştirme yeteneğinin daha üstün olduğunu ve yanlış alarmlara karşı daha dirençli olduğunu göstermektedir. Bu sonuç, uydu katmanında neden YOLOv10s mimarisinin tercih edildiğini somut bir şekilde doğrulamaktadır.



(a) YOLOv8s (Skor: 0.71)



(b) YOLOv12s (Skor: 0.61)



(c) YOLOv10s (Skor: 0.79)

Şekil 4.5. Harici Test Veri Seti (SWIR) Üzerinde Modellerin Tespit Başarısı

4.1.3. YOLOv10 Modelinin Spektral Bant Performans Analizi


Bu aşamada, orman yangını tespitinde kullanılan spektral bantların (True Color, False Color, SWIR, Urban False Color) model başarımı üzerindeki etkisi incelenmiştir. Her bant için Bölüm 3.5.1’deki Tablo 3.4’te belirtildiği üzere izole edilmiş eğitim süreçleri yürütülmüş ve elde edilen sonuçlar nicel (tablo/grafik) ve nitel (görsel) olarak değerlendirilmiştir.

4.1.4. Sayısal Performans Değerlendirmesi

Modellerin test kümesi üzerindeki sayısal performans metrikleri Tablo 4.2’de, bantlar arası performans farkını gösteren korelasyon ısı haritası ise Şekil 4.6’te sunulmuştur.

Tablo 4.2. YOLOv10s Modelinin Farklı Spektral Bantlardaki Performansı

Spektral Bant	Precision	Recall	F1-Score	mAP@50	mAP@50-95
True Color	0.379	0.272	0.317	0.127	0.127
False Color	0.534	0.413	0.466	0.243	0.243
SWIR	0.626	0.578	0.601	0.417	0.417
Urban False Color	0.680	0.543	0.604	0.425	0.425

**Şekil 4.6.** Spektral Bant Performanslarının Isı Haritası

Tablo 4.2 ve Şekil 4.6 incelendiğinde, Urban False Color bandının 0.680 Precision ve 0.425 mAP değeri ile en yüksek tespit başarısını gösterdiği görülmektedir. SWIR bandı ise 0.578 ile en yüksek Recall değerine ulaşarak yangın kaçırma oranını minimize etmiştir.


Buna karşın, True Color (RGB) bandının performansının diğer bantlara kıyasla belirgin şekilde düşük olduğu dikkat çekmektedir. Bu durumun temel nedenleri iki ana faktöre dayanmaktadır:

Veri Dengesizliği (Data Imbalance): Bölüm 3.1.1'deki Tablo 3.1'de detaylandırıldığı üzere, eğitim setindeki True Color görüntü sayısı (yaklaşık 2.400), diğer spektral bantların (yaklaşık 4.200) neredeyse yarısı kadardır. Veri setindeki bu yetersiz temsil, modelin RGB uzayındaki öğrenme kapasitesini sınırlamıştır.

Fiziksel Maskeleye: True Color bandı, görünür ışık spektrumunda çalıştığı için dumanın maskeleye etkisine en çok maruz kalan banttır. SWIR ve Urban bantları dumanın arkasındaki termal radyasyonu yakalayabilirken, RGB bandı yoğun duman altında yangın odağını görselleştirmekte yetersiz kalmaktadır.

4.1.5. Görsel Tespit Analizi

Sayısal verilerin sahadaki karşılığını gözlemlemek amacıyla, aynı yangın sahnesinin dört farklı spektral banttaki görünümü ve modelin ürettiği güven skorları (confidence scores) Şekil 4.7 üzerinde karşılaştırılmıştır.



Şekil 4.7. Aynı Yangın Sahnesinin Farklı Spektral Bantlardaki Tespit Skorları

Şekil 4.7’de (a) bendinde görülen True Color görüntüsünde, yoğun duman yangın bölgesini kapatmış ve model yangını ancak 0.32 gibi düşük bir güven skoruyla tespit edebilmiştir. Buna karşın, dumanın şeffaflaştığı ve ısı kaynağının belirginleştiği SWIR (c) bandında skor 0.70’e yükselmiştir. En çarpıcı sonuç ise (d) bendindeki Urban False Color bandında gözlemlenmiştir. Yangın bölgesinin yüksek kontrastla “neon” parlaklığında ayrıştığı bu bantta model, duman etkisinden tamamen kurtularak 0.90 güven skoruna ulaşmıştır. Bu görsel kanıtlar, orman yangını tespitinde sadece görünür ışığa (RGB) güvenilmemesi gerektiğini ve Urban False Color bandının sisteme entegrasyonunun tespit güvenilirliğini yaklaşık 3 kat artırdığını (0.32 vs 0.90) doğrulamaktadır.

4.2. İHA Katmanında Model Performans Karşılaştırması


Sistemin 3.katmanı olan İHA üzerinde; YOLOv8s, YOLOv10s ve YOLOv12s modellerinin performansları, veri setinin ayrılmış test kümesi üzerinde karşılaştırmalı olarak analiz edilmiştir. Eğitim sürecinde, modelin yanlış alarm (False Positive) oranlarını düşürmek ve arka planı daha iyi ayırt etmesini sağlamak amacıyla veri setine “Other” sınıfı dahil edilmiştir. Ancak, sistemin asıl odak noktası olan yangın ve duman tespit başarımını netleştirmek adına, aşağıdaki performans analizlerinde “Other” sınıfı hesaplama dışı bırakılmış ve metrikler sadece hedef sınıflar (Fire, Smoke) üzerinden türetilmiştir.

4.2.1. YOLO Mimarilerinin Performans Karşılaştırması

Eğitilen modellerin performans sonuçları Tablo 4.3’te detaylandırılmış, modellerin zorlu koşullardaki kararlılığını gösteren $mAP@50-95$ değerleri ise Şekil 4.8’de grafiksel olarak sunulmuştur.

Tablo 4.3. İHA Veri Seti Üzerinde YOLO Modellerinin Performans Karşılaştırması


Model	Precision	Recall	F1-Score	$mAP@50$	$mAP@50-95$
YOLOv8s	0.868	0.827	0.847	0.903	0.640
YOLOv10s	0.858	0.819	0.838	0.902	0.638
YOLOv12s	0.864	0.846	0.855	0.912	0.651




Şekil 4.8. İHA Veri Seti Üzerinde YOLO Modellerinin $mAP@0.5:0.95$ Karşılaştırması

Tablo 4.3 ve Şekil 4.8 incelendiğinde; YOLOv12s modelinin 0.912 $mAP@50$ değeri ve 0.651 $mAP@50-95$ değeri ile tespit başarısı en yüksek model olduğu görülmektedir. Analiz sonuçlarında dikkat çeken en kritik bulgu, YOLOv12s modelinin 0.846 ile en yüksek Recall ve buna bağlı olarak 0.855 ile en yüksek F1-Skoruna sahip olmasıdır. Recall değerinin yüksek


olması, modelin gözden kaçırdığı yangın sayısının (False Negative) minimize edildiği anlamına gelmektedir. YOLOv8s modeli hız avantajı sağlasa da, yangın tespiti gibi hayati risk taşıyan ve “kesin doğrulama” gerektiren senaryolarda hızdan ziyade tespit güvenilirliği (Recall ve mAP) önceliklendirilmiştir. Bu doğrultuda; karmaşık orman zeminlerinde küçük yangın başlangıçlarını kaçırmama yeteneği ve yüksek F1 dengesi nedeniyle İHA katmanı için YOLOv12s mimarisi en uygun aday olarak belirlenmiştir.



(a) YOLOv8s



(b) YOLOv10s




(c) YOLOv12s

Şekil 4.9. İHA Veri Seti Üzerinde Modellerinin F1-Güven (F1-Confidence) Eğrileri

Şekil 4.9’te sunulan F1-Güven (F1-Confidence) eğrileri, eğitilen modellerin değişen güven eşiklerine karşı sergiledikleri harmonik ortalama performansını analiz etmektedir. İdeal bir nesne tespit modelinin, geniş bir güven aralığında yüksek F1 skorunu koruması ve eşik değeri arttıkça ani performans kayıpları yaşamaması beklenir. Grafikler incelendiğinde, özellikle YOLOv12s modelinin eğrisinin diğer modellere kıyasla daha kararlı bir yapı sergilediği ve daha yüksek bir zirve noktasına ulaştığı açıkça görülmektedir. Buna karşın, YOLOv8s ve YOLOv10s modellerine ait eğrilerin belirli bir güven eşiklerinden sonra daha hızlı bir düşüş eğilimine girdiği gözlemlenmiştir. YOLOv12s modelinin yüksek güven değerlerinde dahi performans kararlılığını

koruyarak daha stabil bir hat izlemesi, modelin yanlış alarmlar ile kaçırılan tespitler arasındaki dengeyi en iyi şekilde optimize ettiğini kanıtlamaktadır. Bu görsel bulgu, Tablo 4.3'teki sayısal verileri doğrulamakta olup, hata toleransının çok düşük olduğu İHA tabanlı doğrulama görevlerinde YOLOv12s mimarisinin en güvenilir tercih olduğunu somutlaştırmaktadır.



Şekil 4.10. İHA Veri Seti Üzerinde YOLOv12s Modeline Ait Karmaşıklık Matrisi (Confusion Matrix) Analizi

Şekil 4.10'da sunulan YOLOv12s modeline ait karmaşıklık matrisi, modelin karmaşık İHA görüntülerindeki ayırt etme yeteneğini ve eğitim stratejisinin başarısını ortaya koymaktadır. Matriste dikkat çeken en önemli bulgu, 2130 adet yangın ve 2021 adet duman örneğinin doğru tespit edilmesidir (True Positive). Daha da önemlisi, eğitim setine dahil edilen "Other" sınıfının işlevselliği, matrisin son sütununda (Background) somut olarak görülmektedir. Model, yangın olmayan karmaşık arka plan görüntülerinin 1537 tanesini hatalı bir şekilde "Yangın" olarak etiketlemek yerine "Other" sınıfına atamıştır. Bu durum, "Other" sınıfının sistem içinde bir tampon mekanizma görevi görerek yanlış yangın alarmlarını (False Positive) başarılı bir şekilde absorbe ettiğini kanıtlamaktadır. Gözden kaçan (Background olarak tahmin edilen) yangın sayısı 209 ile sınırlı kalırken, modelin operasyonel önceliği olan yüksek Recall hedefine sadık kaldığı doğrulanmıştır.

4.2.2. Gerçek Zamanlı Hız ve Gecikme Analizi

Otonom İHA'lar üzerindeki gömülü sistemlerin işlemci kapasitesi sınırlıdır. Bu nedenle modellerin çıkarım (inference) hızı kritik öneme sahiptir. Tablo 4.4, modellerin işlem sürelerini

ve FPS değerlerini karşılaştırmaktadır. Hız testi RTX 4060 8GB LAPTOP GPU üzerinde gerçekleştirilmiştir.

Tablo 4.4. İHA Katmanı: Modellerin İşlem Süreleri ve FPS Değerleri

Model	Pre-process	Inference	Post-process	FPS (Yaklaşık)
YOLOv8s	1.0 ms	5.5 ms	0.7 ms	180.95
YOLOv10s	1.0 ms	5.8 ms	0.1 ms	173.62
YOLOv12s	1.0 ms	8.3 ms	0.7 ms	120.38

Hız testlerinde YOLOv8s, 5.5 ms çıkarım süresi ve 181 FPS hız ile en hızlı model olmuştur. Ancak YOLOv10s modeli, NMS aşamasını ortadan kaldıran mimarisi sayesinde 0.1 ms gibi ihmal edilebilir bir post-process süresi sunmuştur. Bu durum, YOLOv10'un özellikle çok sayıda nesnenin olduğu kalabalık sahnelerde daha kararlı bir gecikme süresi (latency) sunabileceğini işaret etmektedir.


YOLOv12s ise daha karmaşık mimarisi (Attention mechanism) nedeniyle 120 FPS ile diğerlerinin gerisinde kalsa da, gerçek zamanlı çalışma sınırı olan 30 FPS'in çok üzerinde olduğu için İHA operasyonları için fazlasıyla yeterlidir.

4.2.3. Görsel Analiz ve Model Karşılaştırması

Sistemin başarısını sadece sayısal metriklerle değil, görsel çıktılar üzerinden de değerlendirmek kritik öneme sahiptir. Bu kapsamda, görsel analiz süreci iki aşamada ele alınmıştır: test veri seti üzerindeki genel başarımlar ve modelin eğitim sırasında hiç görmediği harici görüntüler üzerindeki “zorlu senaryo” performansı.

4.2.4. Test Veri Seti Üzerindeki Başarımlar

İlk aşamada, modelin eğitim ve doğrulama süreçlerinde kullanılan veri dağılımına uygun test görüntüleri üzerindeki performansı incelenmiştir. Şekil 4.11'de sunulan örneklerde görüldüğü üzere, modelimiz (YOLOv12s) karmaşık orman zeminlerinde ve farklı duman yoğunluklarında, yangın ve duman etiketlerini yüksek güven skorlarıyla tespit etmeyi başarmıştır. Bu durum, eğitim sürecinin sağlıklı gerçekleştiğini ve modelin hedef nesneleri doğru öğrendiğini kanıtlamaktadır.



Şekil 4.11. Dahili Test Veri Seti Üzerinde Modellerin Tespit Başarısı

4.2.5. Harici Veriler ve Genelleştirme Testi


Sistemin gerçek dünya koşullarındaki güvenilirliğini test etmek amacıyla, internet kaynaklarından rastgele seçilen ve eğitim setinde kesinlikle bulunmayan “zorlu bir yangın senaryosu” üzerinde YOLOv8s, YOLOv10s ve YOLOv12s modelleri karşılaştırmalı olarak test edilmiştir.

Şekil 4.12’de sunulan bu karşılaştırma, mimari seçiminin önemini çarpıcı bir şekilde ortaya koymaktadır:

YOLOv8s (a) ve YOLOv10s (b): Her iki model de ortamdaki yoğun dumanı başarılı bir şekilde tespit etmiştir. Ancak, dumanın hemen altındaki kıızıl alev kaynağını algılamada başarısız olmuşlardır. Özellikle YOLOv10s’in dumana çok yüksek skor vermesine rağmen alevi kaçırması, modelin sadece belirgin özelliklere (duman) odaklandığını göstermektedir.

YOLOv12s (c): Dikkat Mekanizması (Attention Mechanism) sayesinde sahneyi daha bütüncül analiz etmiştir. Model, dumanı 0.87 skorla tespit etmekle kalmamış, diğer modellerin kör nokta olarak kaçırdığı yangın nesnesini de yakalamayı başarmıştır.

Erken uyarı sistemlerinde, alevin tespit edilmesi (skor düşük olsa bile) hayati önem taşımaktadır. Bu sonuç, İHA katmanında neden YOLOv12s mimarisinin tercih edildiğini ve modelin geliştirme yeteneğinin diğerlerine göre üstün olduğunu somut olarak kanıtlamaktadır.



Şekil 4.12. Harici Veri Seti Üzerinde Modellerin Tespit Başarısı

4.3. Genel Değerlendirme ve Model Seçimi

Bu çalışma kapsamında elde edilen deneysel veriler, farklı YOLO mimarilerinin (v8, v10, v12) her birinin belirli senaryolarda üstünlük sağladığını ortaya koymuştur. Sonuçlar özetlendiğinde:

- **YOLOv8s:** Yüksek Recall ve hızı sayesinde, yangın kaçırma riskinin minimize edilmesinin öncelikli olduğu senaryolar için güçlü bir adaydır.
- **YOLOv12s:** En yüksek mAP ve doğrulama yeteneğine sahip olması nedeniyle, yanlış alarm üretiminin kritik derecede düşük olması gereken ve “kesin doğrulama” yapılan İHA uygulamaları için en uygun modeldir.
- **YOLOv10s:** Parametre verimliliği, yüksek mAP değeri ve dengeli yapısı ile, uydu tabanlı ve çok aşamalı doğrulama içeren geniş alan tarama sistemleri için en mantıklı çözümdür.

Bu doğrultuda; projenin Uydu Katmanı için operasyonel verimliliği nedeniyle YOLOv10s, İHA Katmanı için ise yüksek doğrulama hassasiyeti nedeniyle YOLOv12s modeli nihai sistem mimarisine entegre edilmiştir.

5. SONUÇ VE TARTIŞMA

Bu tez çalışmasında, orman yangınlarının erken evrede tespit edilmesi ve doğrulanması problemini ele alan, uydu ve İnsansız Hava Aracı (İHA) teknolojilerinin entegrasyonuna dayalı otonom ve çift katmanlı bir sistem mimarisi önerilmiştir. Geliştirilen sistemin temel motivasyonu; uydu verilerinin geniş kapsama alanını İHA'ların yüksek çözünürlüklü doğrulama yeteneğiyle birleştirerek, yanlış alarmları minimize eden ve enerji verimliliğini maksimize eden hibrit bir karar mekanizması oluşturmaktır. Çalışma kapsamında elde edilen deneysel bulgular, sistemin başarısını ve literatüre sunduğu katkıları şu başlıklar altında özetlemektedir:

5.1. Sonuçlar

Uydu Katmanında Model ve Spektral Başarım: Sistemin makro analiz katmanını oluşturan uydu modülünde, Sentinel-2 verileri üzerinde gerçekleştirilen testler, YOLO mimarilerinin (v8, v10, v12) performans farklılıklarını ortaya koymuştur. Elde edilen sonuçlar, YOLOv10s modelinin 0.870 mAP@50 ve 0.819 F1-Skoru ile hem tespit doğruluğu hem de işlem hızı açısından en dengeli mimari olduğunu göstermiştir.

Spektral analizlerde ise, literatürde yaygın olarak kullanılan True Color (RGB) bandının duman maskeleymesi nedeniyle yetersiz kaldığı (0.127 mAP), buna karşın çalışmada önerilen Urban False Color bandının dumanın arkasındaki ısı kaynaklarını ayırt etmede yaklaşık 3 kat daha yüksek bir güvenilirlik (0.90 Güven Skoru) sağladığı tespit edilmiştir. Bu bulgu, orman yangını tespitinde sadece görsel (RGB) veriye dayalı sistemlerin güvenilirmez olduğunu ve multispektral analizin zorunluluğunu kanıtlamaktadır.

İHA Katmanında Doğrulama Hassasiyeti: Sistemin mikro doğrulama aşamasında, karmaşık zeminlerdeki küçük yangın başlangıçlarını tespit etme yeteneği kritik öneme sahiptir. İHA veri seti üzerinde yapılan testlerde, YOLOv12s modeli, sahip olduğu dikkat mekanizması (attention mechanism) sayesinde 0.912 mAP@50 ve 0.846 Recall değerlerine ulaşarak, rakiplerine (v8 ve v10) kıyasla en yüksek başarıyı sergilemiştir. Özellikle harici veri setlerinde yapılan “zorlu senaryo” testlerinde, diğer modellerin sadece dumanı algılayıp alevi kaçırdığı durumlarda, YOLOv12s’in alev kaynağını da başarıyla tespit etmesi, modelin genelleştirme yeteneğinin üstünlüğünü doğrulamaktadır.

Sistem Mimarisi ve Enerji Verimliliği: Önerilen hiyerarşik yapı; İHA'ların rastgele devriye gezmesi yerine, yalnızca uydu tarafından “yüksek şüphe” ile işaretlenen koordinatlara yönlendirilmesi prensibine dayanmaktadır. Bu yaklaşım, İHA operasyon süresini ve enerji tüketimini optimize ederken, yanlış alarmlardan kaynaklanan gereksiz kalkışları da engellemiştir.

Uydu katmanındaki YOLOv10s'in hızı ve İHA katmanındaki YOLOv12s'in hassasiyeti, sistemin gerçek zamanlı uygulanabilirliğini artıran en önemli faktörlerdir.

5.2. Tartışma

Bu çalışmanın en önemli çıktısı, orman yangını tespitinde tek bir modelin veya tek bir veri kaynağının yeterli olmadığı gerçeğidir. Literatürdeki birçok çalışmanın yalnızca uydu veya yalnızca İHA görüntülerine odaklandığı göz önüne alındığında, bu tezde sunulan hibrit yaklaşımın, her iki platformun zayıf yönlerini (uydunun düşük mekânsal çözünürlüğü ve İHA'nın sınırlı menzili) birbirini tamamlayacak şekilde ele aldığı görülmektedir [5, 10, 26].

Özellikle spektral analiz bölümünde elde edilen bulgular, yangın tespit algoritmalarının başarısının yalnızca model mimarisine değil, aynı zamanda probleme uygun spektral bilginin modele sunulmasına da güçlü biçimde bağlı olduğunu ortaya koymuştur [34, 24]. True Color görüntülerde duman altında kalan yangın bölgelerinin, Urban False Color ve SWIR tabanlı kompozitlerde daha net biçimde ayrışması, çok bantlı uydu verilerinin yangın algılama sistemlerindeki kritik rolünü desteklemektedir [23, 24].

Bununla birlikte, çalışmanın bazı sınırlılıkları da bulunmaktadır. Sistemin uydu katmanı, Sentinel-2 uydusunun geçiş sıklığına (revisit time) bağlı olup, bu durum anlık ve sürekli izleme gerektiren senaryolarda tespit süresini kısıtlayabilmektedir [35]. Benzer şekilde, gece koşullarında optik tabanlı İHA görüntülerinin yetersiz kalması, sistemin 7/24 operasyonel kabiliyetini sınırlayan temel faktörlerden biridir [9, 18].

Canlı Veri Entegrasyonu: Mevcut çalışmada testler statik veri setleri üzerinden gerçekleştirilmiştir. Gelecek çalışmalarda, Sentinel-2 ve VIIRS uydularından gelen verilerin gerçek zamanlı (real-time) olarak sisteme akmasını sağlayacak API entegrasyonlarının yapılması ve canlı veri akışının veritabanı ile senkronize edilmesi hedeflenmelidir. Bu tür gerçek zamanlı uzaktan algılama entegrasyonlarının, erken yangın tespit sistemlerinin operasyonel başarımını artırdığı literatürde de rapor edilmiştir [7, 35].

5.2.1. Gelecek Çalışmalar ve Öneriler

Bu tez çalışmasında, önerilen otonom orman yangını tespit sisteminin kavramsal mimarisi tasarlanmış, derin öğrenme modelleri eğitilmiş ve bu modellerin başarım testleri gerçekleştirilmiştir. Sistemin tam teşekküllü bir operasyonel yapıya kavuşması ve sahada aktif olarak kullanılabilmesi için aşağıdaki geliştirme adımlarının atılması önerilmektedir:

Yazılım Altyapısının Geliştirilmesi (Backend & Frontend): Önerilen mimarinin çalışabilmesi için gerekli olan sunucu tabanlı arka uç (backend) servislerinin ve kullanıcı arayüzlerinin (frontend) geliştirilmesi gerekmektedir. Özellikle model çıkarımlarının (inference)

sunucu tarafında işlenmesi, veritabanı bağlantılarının kurulması ve operatörlerin sistemi izleyebileceği bir yönetim panelinin kodlanması, projenin bir sonraki temel aşamasını oluşturmaktadır.

Canlı Veri Entegrasyonu: Mevcut çalışmada testler statik veri setleri üzerinden yapılmıştır. Gelecek çalışmalarda, Sentinel-2 ve VIIRS uydularından gelen verilerin gerçek zamanlı (real-time) olarak sisteme akmasını sağlayacak API entegrasyonlarının yapılması ve canlı veri akışının veritabanı ile senkronize edilmesi hedeflenmelidir.

Otonom İHA İstasyonları Ağı: Sistemin geniş ormanlık alanlarda kesintisiz hizmet verebilmesi için, tek bir İHA yerine belirli aralıklarla yerleştirilmiş “İHA Şarj ve Kalkış İstasyonları” ağının kurulması önerilmektedir. Yangın riski yüksek bölgelere stratejik olarak konumlandırılacak bu istasyonlar sayesinde, uydu tetiklemesi aldığı anda olay yerine en yakın İHA’nın yönlendirilmesi sağlanarak müdahale süresi minimize edilebilir.

Donanım Üzerinde Optimizasyon (Edge AI): Geliştirilen YOLO modellerinin, bulut sunucusu yerine İHA üzerindeki gömülü sistemlerde (NVIDIA Jetson, Raspberry Pi vb.) çalıştırılabilmesi için model sıkıştırma (pruning/quantization) teknikleriyle optimize edilmesi, sistemin internet bağımsız çalışabilmesi adına kritik bir geliştirme olacaktır.

KAYNAKLAR

- [1] Bowman D.M.J.S. vd., Fire in the Earth system, *Science*, vol. 324, no. 5926, 481-484, 2009.
- [2] San-Miguel-Ayanz J. vd., Forest fire detection and monitoring using remote sensing, European Commission – Joint Research Centre, 2013.
- [3] Filippi A.M., Boschetti L., Remote Sensing of Fires, *Remote Sensing*, vol. 12, no. 11, 1800, 2020.
- [4] Yuan C., Zhang Y., Liu Z., A survey on technologies for automatic forest fire detection, *Sensors*, vol. 15, no. 12, 31282–31317, 2015.
- [5] Barmpoutis P., Papaioannou P., Dimitropoulos K., Grammalidis N., A review on early forest fire detection systems using optical remote sensing, *Sensors*, vol. 20, no. 22, 6442, 2020.
- [6] Giglio L., Schroeder W., Justice C.O., The collection 6 MODIS active fire detection algorithm and fire products, *Remote Sensing of Environment*, vol. 178, 31–41, 2016.
- [7] Schroeder W., Oliva P., Giglio L., Csiszar I.A., The New VIIRS 375 m active fire detection data product: Algorithm description and initial assessment, *Remote Sensing of Environment*, vol. 143, 85-96, 2014.
- [8] Toulouse T., Rossi L., Campana A., Celik T., Akhloufi M.A., Computer vision for autonomous UAV flight safety: An overview and a vision-based application, *Fire*, vol. 2, no. 1, 5-15, 2019.
- [9] Merino L., Caballero F., Martínez-de-Dios J.R., Ferruz J., Ollero A., An unmanned aircraft system for automatic forest fire monitoring and measurement, *Journal of Intelligent & Robotic Systems*, vol. 65, no. 1–4, 533–548, 2012.
- [10] Kumar R. vd., Hybrid satellite-UAV wildfire detection systems: A review, *Information Fusion*, 2024.
- [11] Muhammad K., Ahmad J., Mehmood I., Rho S., Baik S.W., Convolutional neural networks based fire detection in surveillance videos, *IEEE Access*, vol. 6, 18174–18183, 2018.
- [12] Zhao Z. vd., Forest fire detection system based on deep learning, *International Journal of Distributed Sensor Networks*, vol. 15, no. 10, 2019.
- [13] Li Y., Zhang H., Shen Q., Real-time forest fire detection using deep learning and UAV imagery, *IEEE Access*, vol. 8, 194057–194068, 2020.
- [14] Yuan F. vd., False alarm reduction in forest fire detection, *Fire Safety Journal*, 2017.
- [15] Chen X. vd., Reducing false positives in fire detection using deep learning, *Pattern Recognition Letters*, 2022.
- [16] Li W. vd., Object detection based on YOLO for remote sensing images, *Remote Sensing*, 2019.
- [17] Kim J., Lee J., Forest fire detection using YOLO and satellite imagery, *Sensors*, 2020.
- [18] Kyrkou C., Theocharides T., Deep-learning-based UAVs for real-time wildfire detection, *IEEE Embedded Systems Letters*, 2021.
- [19] Rossi L. vd., UAV-based wildfire monitoring: A deep learning approach, *Fire Safety Journal*, 2023.
- [20] Lillesand T., Kiefer R., *Remote Sensing and Image Interpretation*, Wiley, USA, 2015.
- [21] Justice C.O. vd., MODIS fire products, *Remote Sensing of Environment*, 2002.

- [22] Filippi A.M., Boschetti L., Satellite remote sensing of active fires: A review, *Remote Sensing*, vol. 13, no. 5, 2021.
- [23] Chuvieco E. vd., Historical background and current developments for mapping burned area from satellite Earth observation, *Remote Sensing of Environment*, 2022.
- [24] Kaufman Y.J. vd., Detection of fires using mid-infrared satellite data, *IEEE Transactions on Geoscience and Remote Sensing*, 1998.
- [25] Frizzi S. vd., Convolutional neural networks for fire detection, *Fire Safety Journal*, 2016.
- [26] Almeida D. vd., Multi-layer decision systems for wildfire early warning, *Expert Systems with Applications*, 2023.
- [27] Ko B.C., Early fire detection using CNNs, *Pattern Recognition Letters*, 2013.
- [28] Girshick R. vd., Rich feature hierarchies for object detection (R-CNN), *Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR)*, 2014.
- [29] Liu W. vd., SSD: Single Shot MultiBox Detector, *European Conference on Computer Vision (ECCV)*, Springer, 2016.
- [30] Redmon J., Divvala S., Girshick R., Farhadi A., You Only Look Once: Unified, Real-Time Object Detection, *Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR)*, 2016.
- [31] Redmon J., Farhadi A., YOLO9000: Better, Faster, Stronger, *Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR)*, 2017.
- [32] Redmon J., Farhadi A., YOLOv3: An Incremental Improvement, *arXiv preprint arXiv:1804.02767*, 2018.
- [33] Jocher G. vd., YOLOv8 documentation and architecture, *Ultralytics*, 2023.
- [34] Zhao F. vd., Multi-spectral fire detection using SWIR bands and CNNs, *IEEE Geoscience and Remote Sensing Letters*, 2022.
- [35] Zhang Y. vd., Forest fire detection using Sentinel-2 imagery and deep learning, *Remote Sensing*, vol. 15, 2023.
- [36] Wang C.Y. vd., YOLOv10: Real-time end-to-end object detection, *arXiv preprint arXiv:2405.14458*, 2024.
- [37] Ultralytics, YOLOv12: Attention-based object detection, *Ultralytics Technical Report*, 2024.
- [38] Pan S.J., Yang Q., A Survey on Transfer Learning, *IEEE Transactions on Knowledge and Data Engineering*, vol. 22, no. 10, 1345-1359, 2010.
- [39] Weiss K., Khoshgoftaar T.M., Wang D., A survey of transfer learning, *Journal of Big Data*, vol. 3, no. 1, 1-40, 2016.
- [40] Lin T.Y. vd., Microsoft COCO: Common objects in context, *European Conference on Computer Vision (ECCV)*, Springer, 740-755, 2014.
- [41] Shorten C., Khoshgoftaar T.M., A survey on Image Data Augmentation for Deep Learning, *Journal of Big Data*, vol. 6, no. 1, 1-48, 2019.

ÖZGEÇMİŞ

Adı Soyadı : Ali EROL
Doğum Tarihi : 19.01.2000
E-posta : erolali4819@gmail.com
Öğrenim Durumu : Lisans, Fırat Üniversitesi,
4. Sınıf Bilgisayar Mühendisliği Öğrencisi



Adı Soyadı : Ahmet MEŞİŞ
Doğum Tarihi : 05.06.2003
E-posta : a.meshish@gmail.com
Öğrenim Durumu : Lisans, Fırat Üniversitesi,
4.Sınıf Bilgisayar Mühendisliği Öğrencisi

